

Tema 7.1

Modelos generativos para visión

Deep Learning

Máster Oficial en Ingeniería Informática

Universidad de Sevilla

Contenido


- Aprendizaje no supervisado
- Autoencoders
- Variational Autoencoders (VAE)
- Generative Adversarial Networks (GAN)
- Modelos de difusión (diffusion models)

Aprendizaje no supervisado

- Hasta ahora nos hemos enfocado en Deep Learning con aprendizaje supervisado.
- Aprendizaje **supervisado**:
 - Datos: los ejemplos son del tipo (X,Y) , hay etiquetas!
 - Objetivo: aprender una función que mapee X a Y .
- Aprendizaje **no supervisado**:
 - Datos: los ejemplos son del tipo (X) . Más fácil de conseguir!
 - Objetivo: descubrir alguna estructura en los datos.
- Veremos a continuación ejemplos de no supervisado.

Autoencoders

- Analicemos qué pasa si buscamos que la salida de una red sea exacta a la entrada (sobre un conjunto de datos limitado).
- Y ahora además pongamos varias capas en medio, con distintos tamaños: aprender la función identidad
- Si se consigue calcular la salida correctamente:
 - ¿qué ha pasado en medio de la red?
 - ¿qué información dan los valores calculados en las capas intermedias?



Autoencoders

- **Encoder:**

- CNN con ReLU
- Reducción de dimensionalidad: Z es menor que X.
- Z = **vector/representación latente**


- **Decoder:**

- **CNN transpuesta** con ReLU
- Obtiene X'

- Función de pérdida:


- L2-norm: $\|X - X'\|^2$

- Uso: inicializar modelo supervisado




Variational Autoencoders

- En autoencoders, si muestreamos el espacio representado en Z conseguimos una salida!
 - Problema: Z no es continuo, y reconstruiríamos lo mismo que lo aprendido
- **VAE**: el espacio latente es continuo, y se muestrea aleatoriamente
- El espacio latente son dos vectores: [[Kingma et al 2013](#)] [[Rezende et al 2014](#)]
 - μ : media de distribución
 - σ : desviación estándar
- A continuación se muestrea aleatoriamente (*Sample*) de una normal $N(\mu, \sigma^2)$



Variational Autoencoders

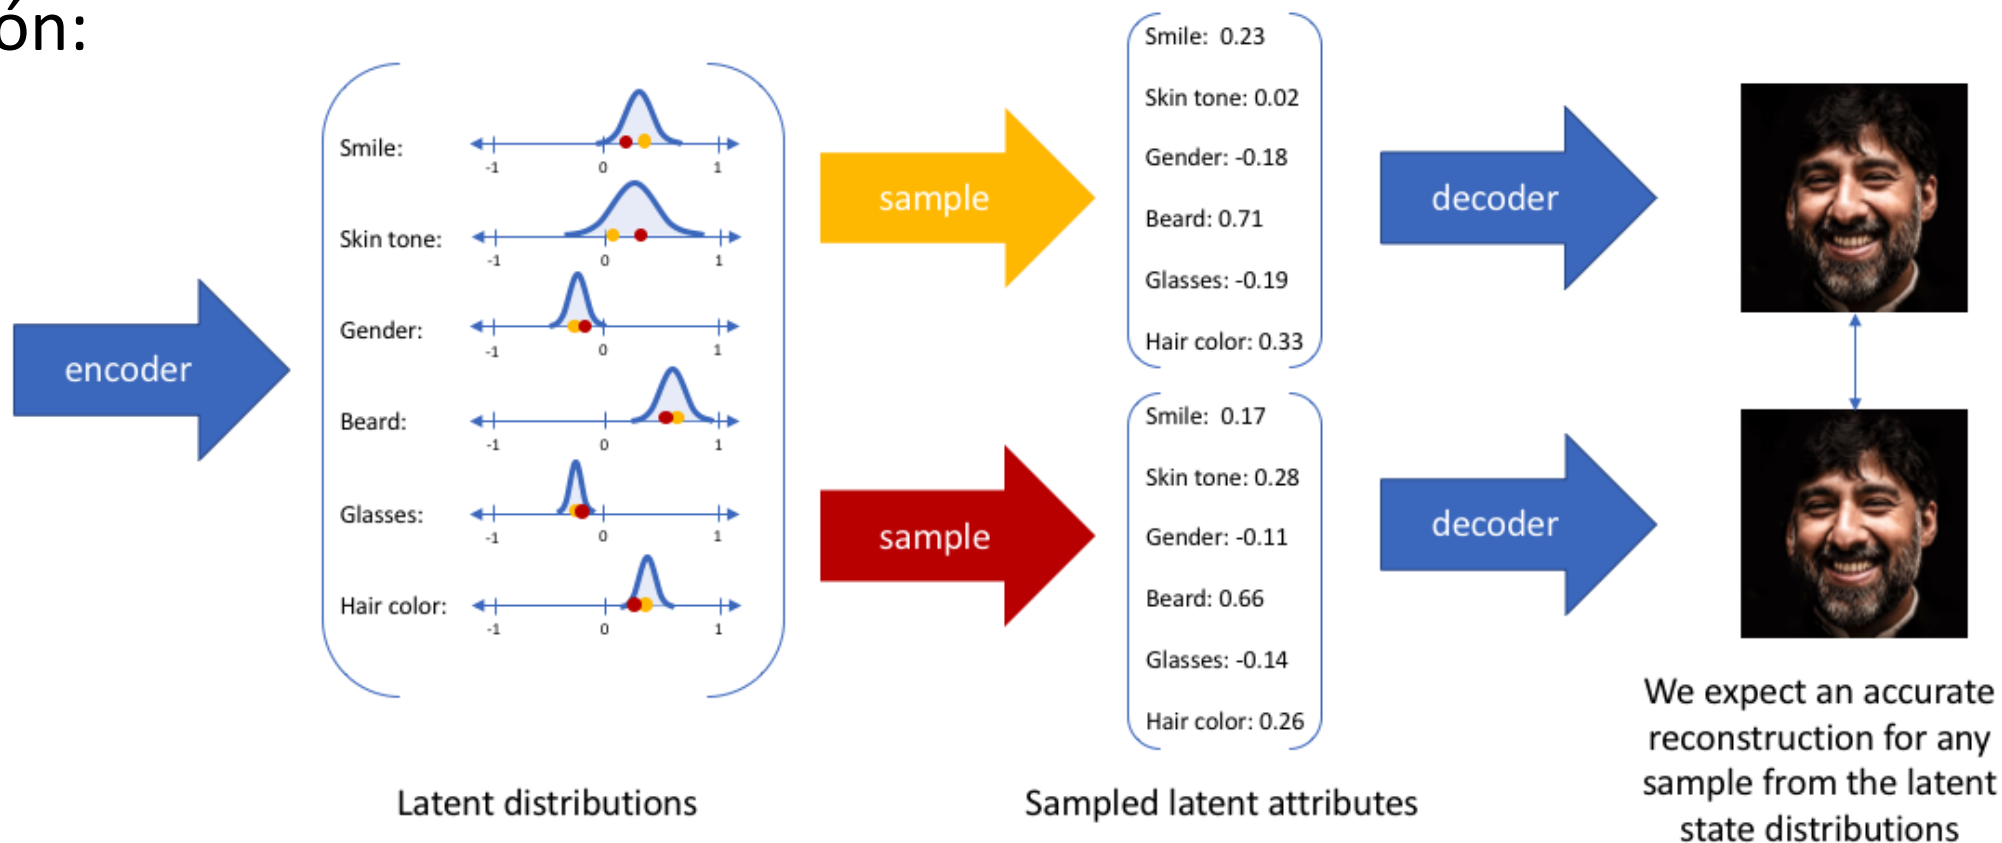
- Intuición:



<https://www.jeremyjordan.me/variational-autoencoders/>

Variational Autoencoders

- Intuición:



<https://www.jeremyjordan.me/variational-autoencoders/>

Variational Autoencoders


- Ejemplos:



Espacio continuo de caras con VAEs (por T. White)

Variational Autoencoders

- Ejemplos (variando atributo específico):



Variando el vector de sonrisa

Generative Adversarial Networks

- Enfrentar dos redes:

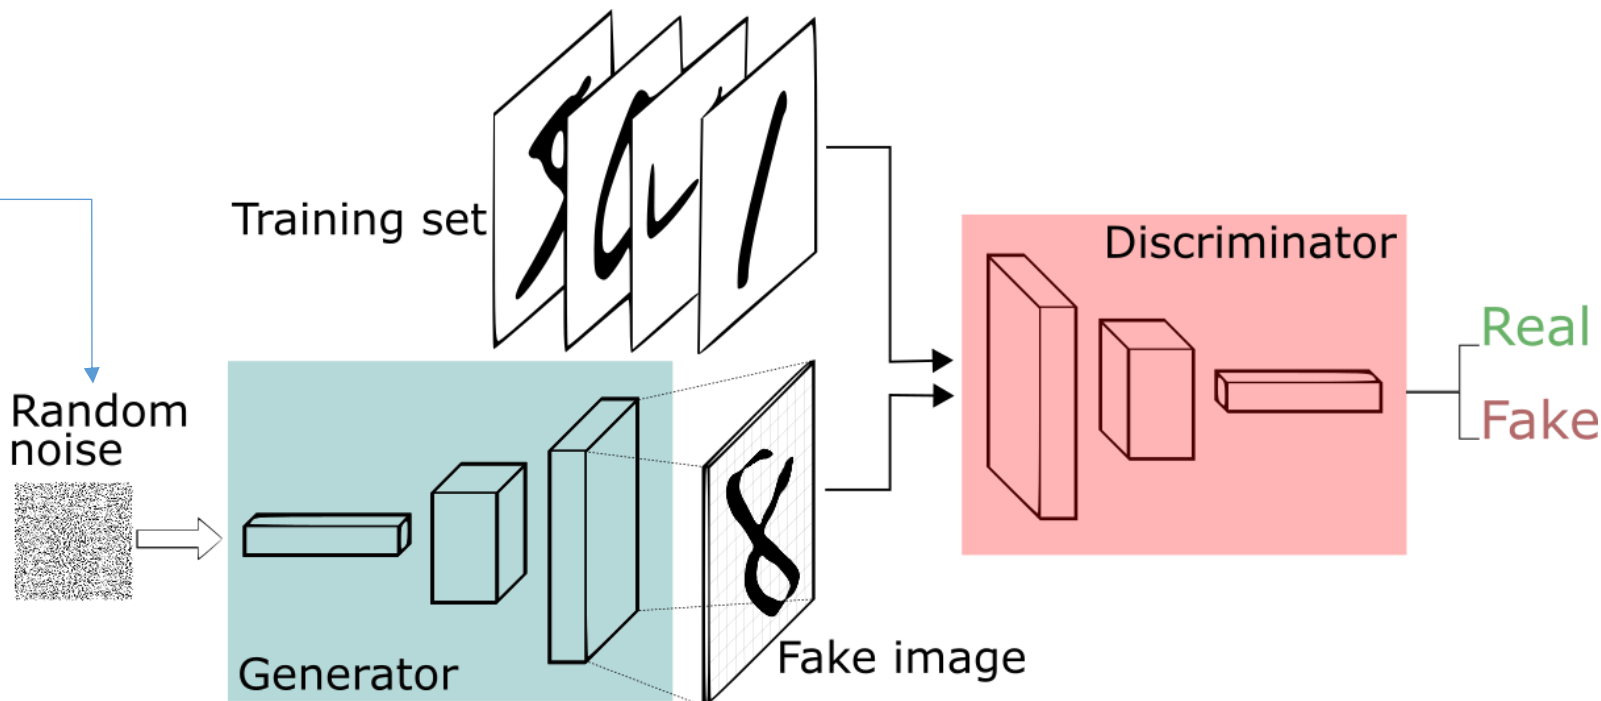
Generative Adversarial Networks (GANs)



Generative Adversarial Networks

- Arquitectura: [[Goodfellow 2014](#)]

- Generador:** Genera ejemplos muestreando aleatoriamente vector latente
- Discriminador (adversaria):** determina si los ejemplos (mezclando del training set y del generador) recibidos son falsos o reales



Generative Adversarial Networks

- El generador se adapta a generar imágenes más realistas cada vez porque el discriminador también se hace más bueno encontrándolas
- Problema: el mínimo óptimo no está garantizado
 - En cada paso del descenso por gradiente, el paisaje de montaña cambia un poco
 - Es un sistema dinámico que busca el equilibrio, no el mínimo
 - Muy difíciles de entrenar (tanto que el mismo autor sacó otro artículo demostrando que no funcionaba en la práctica)

Generative Adversarial Networks

- Guía para Deep Convolutional GANs estables [\[Radford et al 2016\]](#)
 - Reemplazar capas de pooling for strided convolutions (en discriminador) y fractional-strided convolutions (en generador)
 - Usar BatchNorm en discriminador y generador
 - Eliminar capas ocultas totalmente conectadas (FC) para más profundidad
 - En generador, usar activación ReLU para todas las capas menos para la última, que usa tanh
 - En el discriminador, usar LeakyReLU para todas las capas.


Generative Adversarial Networks

- Ejemplos: [[Goodfellow 2014](#)]



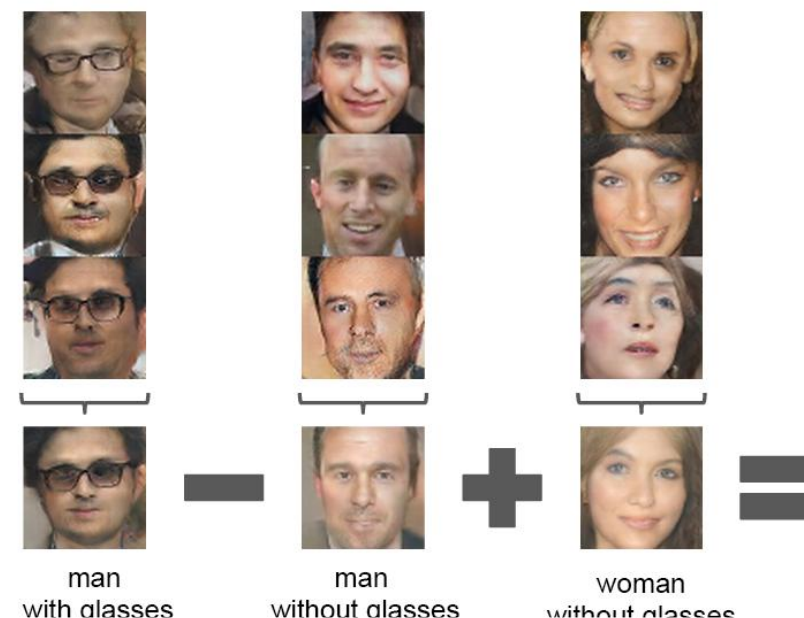
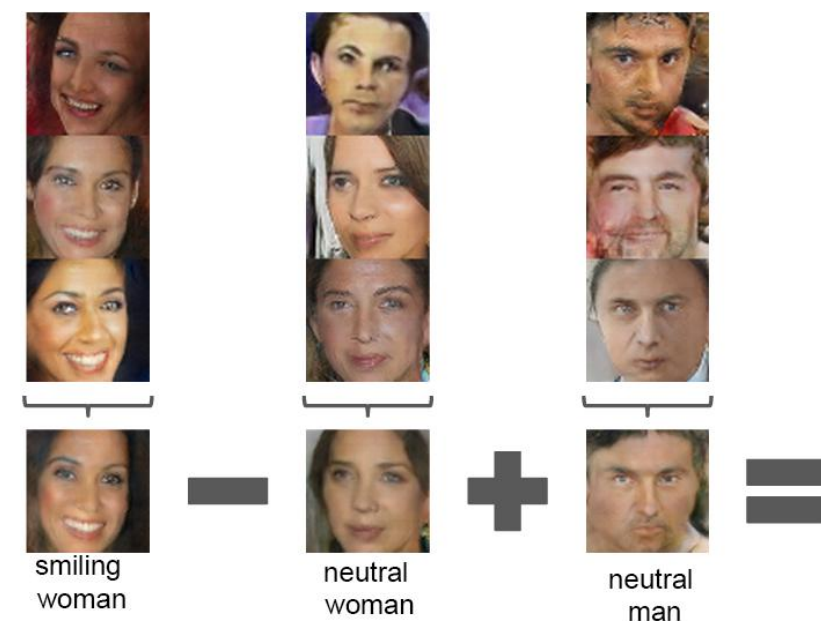
Generative Adversarial Networks

- Ejemplos: [Radford et al 2016]




Generative Adversarial Networks

- Ejemplos de aritmética de vectores para conceptos visuales: [Radford et al 2016]



Generative Adversarial Networks

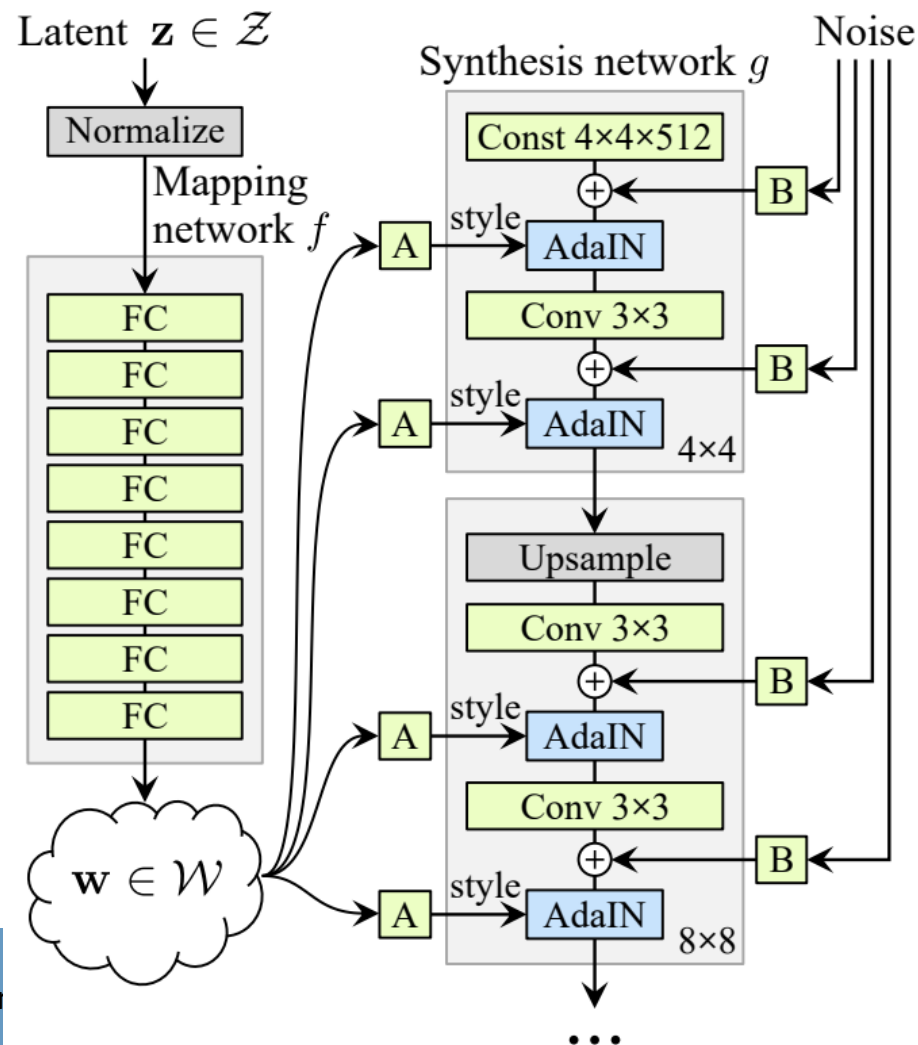
- Problema del colapso del generador



- Solución:
 - Otras funciones de coste, como la Wasserstein (WGAN)
 - Intercalar generadores con resolución creciente

Generative Adversarial Networks

- StyleGAN [[Karras et al 2018](#)]:
 - Dos fuentes de aleatoriedad para el generador
 - Style (ruido por pixel)
 - Noise
 - El generador por fases de creciente resolución $(4 \times 4) \rightarrow (8 \times 8) \rightarrow (16 \times 16) \dots \rightarrow (1024 \times 1024)$



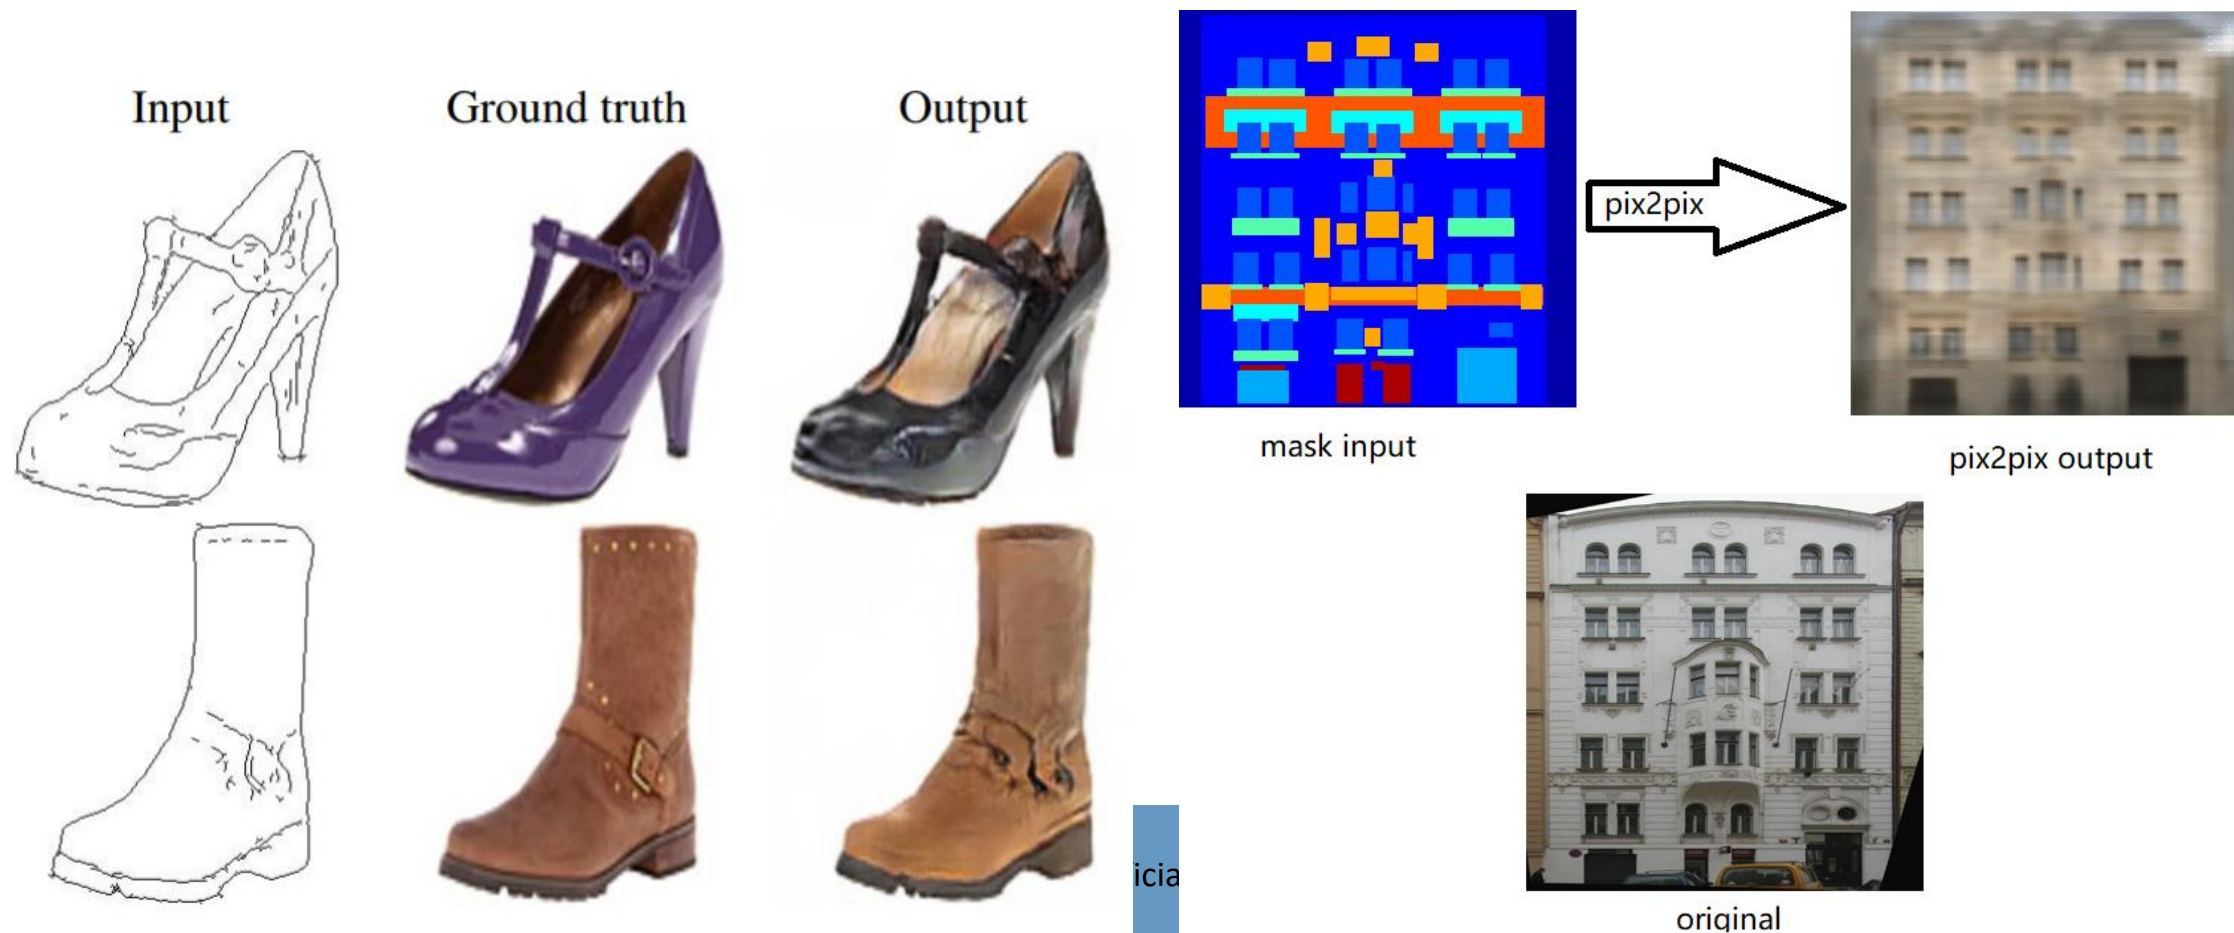
Generative Adversarial Networks

- StyleGAN:



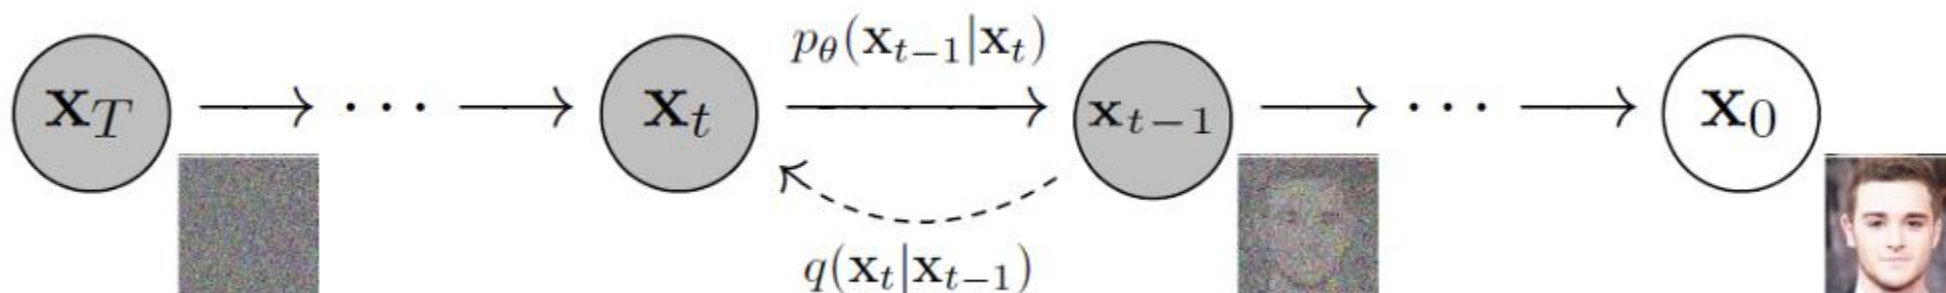
Generative Adversarial Networks

- Pix2pix: basado en cGAN (GANs condicionadas) [[Isola et al 2018](#)]

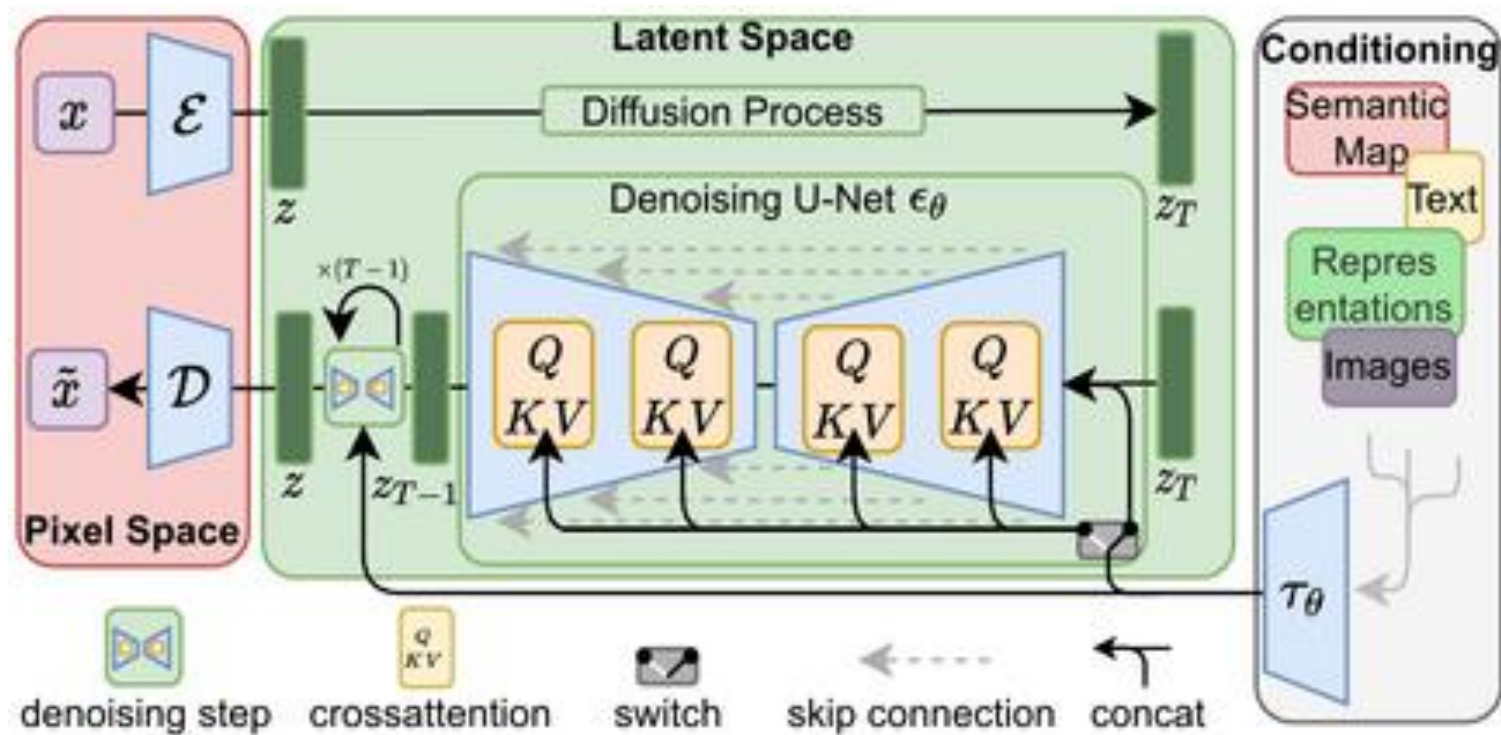


Modelos de difusión

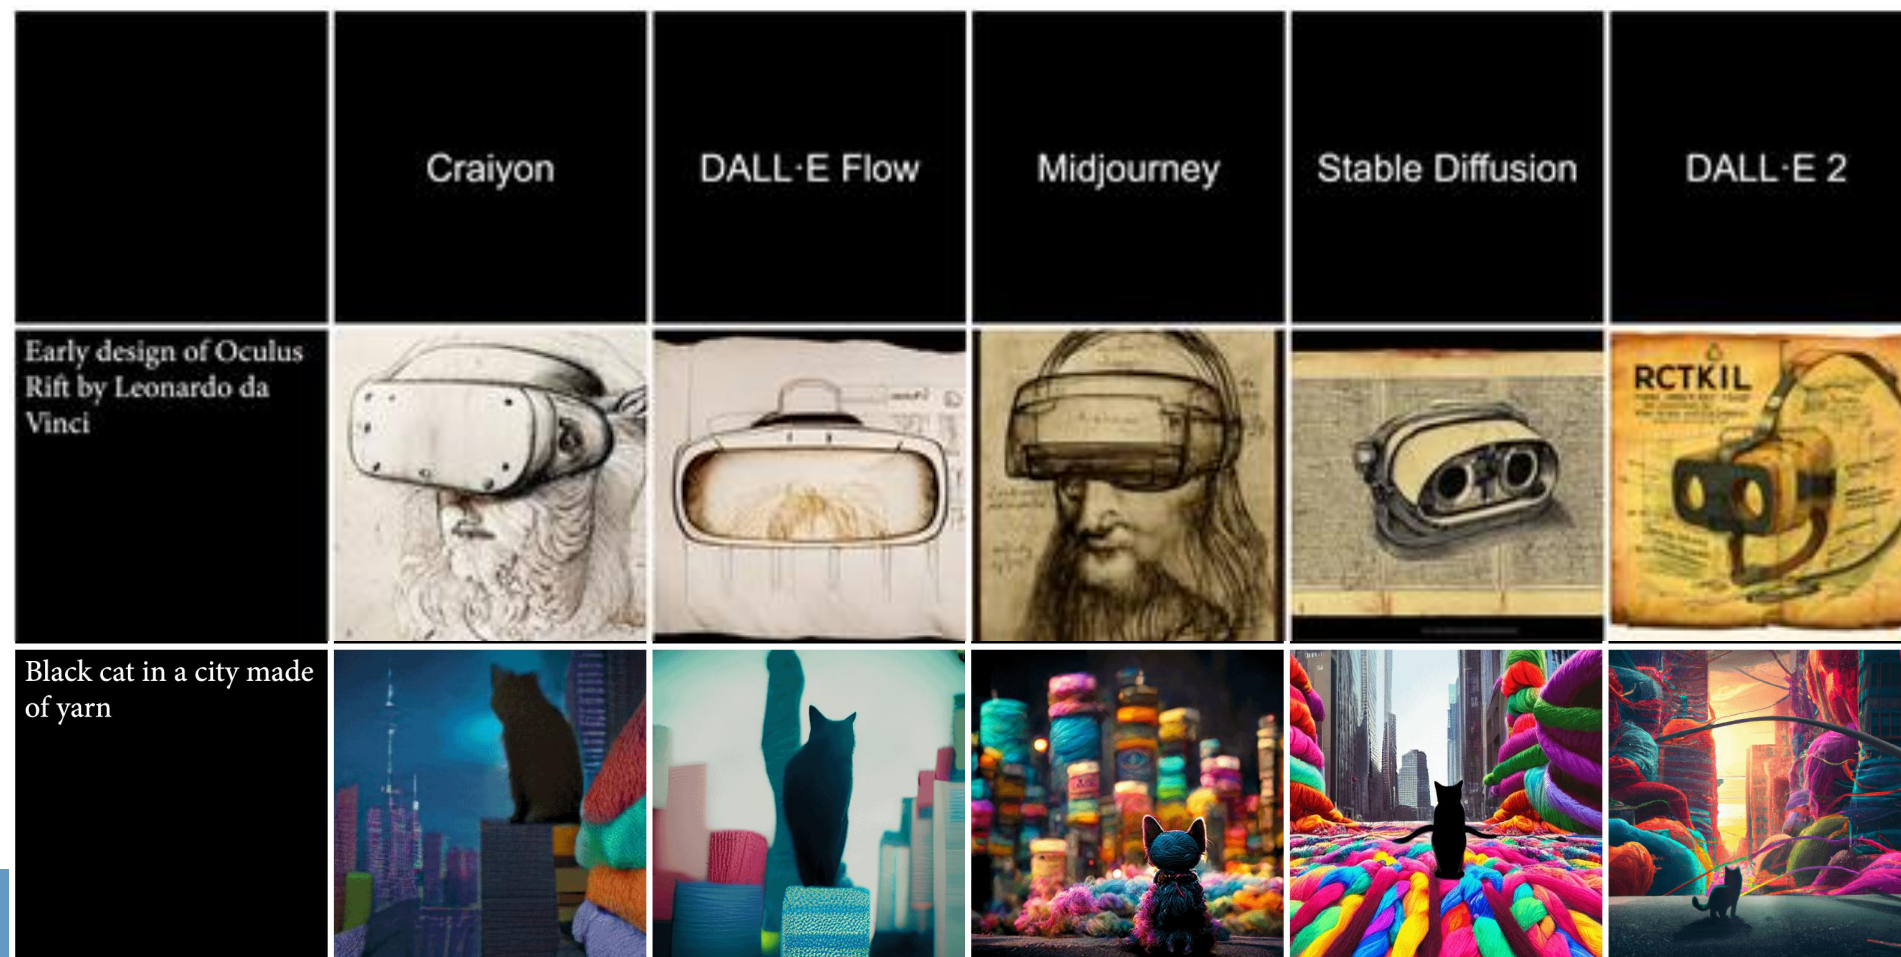
- Se basa añadir (y quitar) ruido gaussiano sobre señales (valores de ruido que siguen una distribución de campana de Gauss).
 - **Forward**: añadimos ruido gaussiano a una imagen por pasos. El ruido añadido en cada paso es independiente de los anteriores (cadena de Markov)
 - **Backward**: eliminamos el ruido añadido a una imagen en un paso dado.



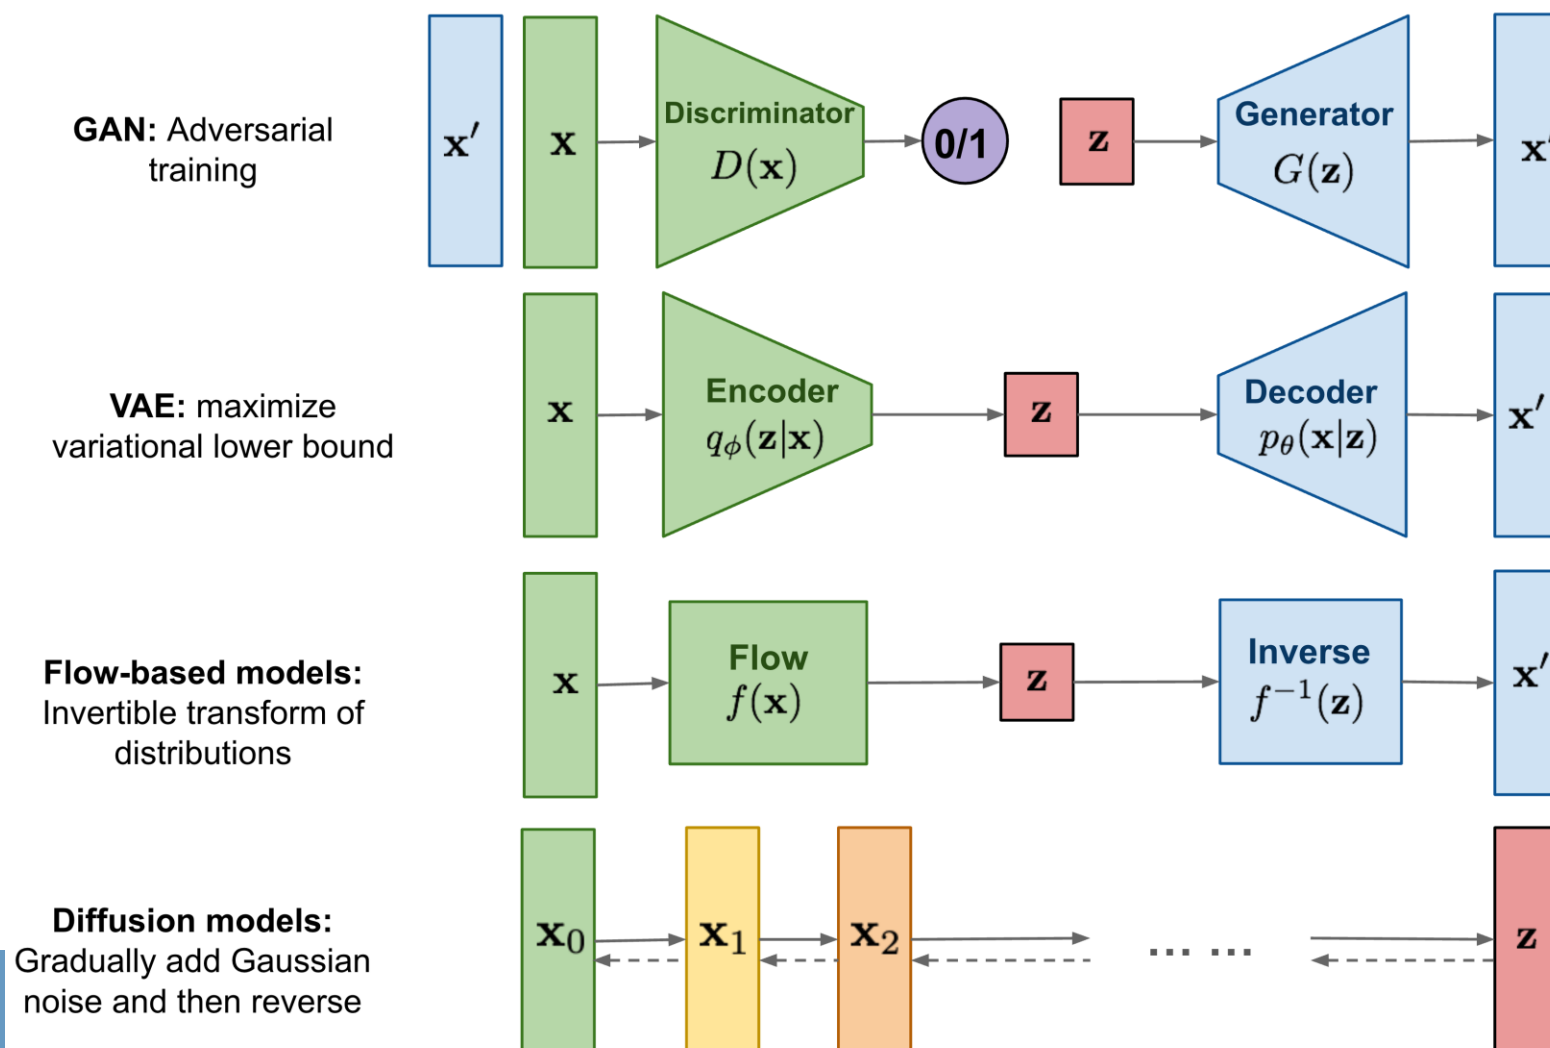
Modelos de difusión condicionados



Modelos de difusión condicionados con texto



Resumen de modelos generadores



Comparativa de modelos generadores

